


سؤال 1: feasible set به شکل زیر خواهد بود:



حال بایست که این feasible set می تواند به راحتی optimal values, optimal set
توابع هدف را به دست آورد

(a) $x^* = (2/5, 1/5)$ بایست که شکل مشخص است

(b) تابع بر روی feasible set unbounded below است.

(c) $x_{opt} = \{(0, x_2) | x_2 \geq 1\}$ بایست که شکل کسری مقدار x_1 در feasible set

برای 0 است نقطه ای ابتدایی خط $x_1 = 0$ بر روی feasible set، $(0, 1)$

است پس $x_2 \geq 1$

(d) $x^* = (1/3, 1/3)$

(e) $x^* = (1/2, 1/6)$ \checkmark $2x_1 + x_2 = 7/6 > 1$

\checkmark $x_1 + 3x_2 = 1 > 1$

$\nabla f_0(x^*) = (1, 3)$ که بر خط $x_1 + 3x_2 = 1$ عمود است

(a)

①

 $\text{unbounded, dom } f_0 \Rightarrow \exists v \in \mathbb{R}^n, v \neq 0, Av \leq 0$

اثبات: فرض میکنیم x^k دنباله‌ای از نقاط در $\text{dom } f_0$ با $\|x^k\| \rightarrow \infty$ باشد (باقی).
 این که $\text{unbounded, dom } f_0$ است، بدان این فرض را کردیم. حال تقریباً میکنیم
 $u^k = x^k / \|x^k\|_2$. این دنباله یک convergent subsequence دارد. این دلیل که $\|u^k\|_2 = 1$ یعنی این دلیل که
 این sequence bounded است. فرض کنیم u حد این convergent subsequence باشد و چون
 $\alpha_i u^k \leq b_i / \|x^k\|_2$ برای هر i برقرار است پس $\alpha_i u \leq 0$ زیرا برای $u \neq 0$ و $Av \leq 0$
 برقرار است

② $\exists v \in \mathbb{R}^n, v \neq 0, Av \leq 0 \Rightarrow \text{unbounded, dom } f_0$

اثبات: اگر چنین v ای موجود باشد، داریم $x_0 + tv \in \text{dom } f_0$ برای هر $t \geq 0$ پس
 $\text{unbounded, dom } f_0$ است.

(b)

① $\exists v \in \mathbb{R}^n, Av \leq 0, Av \neq 0 \Rightarrow f_0$ unbounded below است

اثبات: فرض کنید که $a_j^T v < 0$ مختصراً از $Av \leq 0$ باشد $(Av \leq 0, Av \neq 0)$ که مفروضه
 یعنی $a_j^T v < 0$ برای $t \geq 0$ می‌نویسیم:

$$\begin{aligned} f_0(x_0 + tv) &= - \sum_{i=1}^m \log(b_i - a_i^T x_0 - t a_i^T v) \\ &\leq - \sum_{i \neq j}^m \log(b_i - a_i^T x_0) - \log(b_j - a_j^T x_0 - t a_j^T v) \end{aligned}$$

بنابراین با افزایش t ، سمت راست تساوی بدون bound می‌ماند.
پس f_0 ، unbounded below است.

② f_0 unbounded below است $\Rightarrow \exists v \in \mathbb{R}^n, Av \leq 0, Av \neq 0$

اثبات: فرض کنید f_0 ، unbounded below باشد. x^k را یک دنباله با $-Ax^k > 0$ در نظر بگیرید و داریم $f_0(x^k) \rightarrow -\infty$ با توجه به convexity داریم:

$$f_0(x^k) \geq f_0(x_0) + \sum_{i=1}^m \frac{1}{b_i - a_i^T x_0} a_i^T (x^k - x_0) = f_0(x_0) + m - \sum_{i=1}^m \frac{b_i - a_i^T x^k}{b_i - a_i^T x_0}$$

پس بنابراین اگر $f_0(x^k) \rightarrow -\infty$ باشد، باید داشته باشیم $\max_i (b_i - a_i^T x^k) \rightarrow \infty$

فرض کنید z وجود داشته باشد که $z > 0$ و $A^T z = 0$ برقرار باشند پس

$$z^T b = z^T b - \underbrace{z^T A x^k}_0 = z^T (b - A x^k) \geq z_i \max_i (b_i - a_i^T x^k) \rightarrow \infty$$

لکه که این تناقض است که نشان می‌دهد چنان z ای وجود ندارد، با توجه به قضیه
اشاره در صورت سوال، z ای وجود دارد که مثلاً $Av \leq 0$ و $Av \neq 0$ برقرار باشند.

(ع) اگر f_0 bounded below باشد \Rightarrow حداقل n به دست آمده است این به آن معنی
است که z ای وجود دارد که شرط optimality را satisfy می‌کند.

(d) در این مسئله نیز فرض کنیم: $\text{rank } A = n$ ؛
 به نشان دهیم f_0 حداکثر یک نقطه optimal دارد.

$$\nabla^2 f(x) = A^T \text{diag}(A) A, \quad d_i = \frac{1}{(b_i - a_i^T x)^2}, \quad i = 1, 2, \dots, m$$

$\nabla^2 f(x)$ positive definite است اگر $\text{rank } A = n$ که برای این معنی است که f_0 strictly convex است. پس اگر نقطه optimal وجود داشته باشد، منحصر به فرد است.

سؤال 3: مسئله را به شکل زیر مدل کرد:

$$\begin{aligned} & \text{maximize} \quad \sum_{j=1}^n r_j(x_j) \\ & \text{subject to} \quad x \geq 0 \\ & \quad \quad \quad Ax \leq c^{\max} \end{aligned}$$

این یک مسئله convex optimization است. این را بدانیم که تابع هدف concave است و constraint ها هم set از linear inequality ها هستند. برای تبدیل به L^p معادله ابتدا توابع درآمد را به شکل زیر نشان می دهیم:

$$r_j(x_j) = \min \{ p_j x_j, p_j q_j + p_j^{\text{disc}} (x_j - q_j) \}$$

که از این شکل نتیجه می شود که $r_j(x_j) \geq u_j$ اگر و تنها اگر $p_j x_j \geq u_j$ و $p_j q_j + p_j^{\text{disc}} (x_j - q_j) \geq u_j$

LP معادله را به شکل زیر در نظر بگیرید:

$$\begin{aligned} \text{maximize} \quad & \mathbf{1}^T \mathbf{u} \\ \text{subject to} \quad & \mathbf{x} \geq 0 \end{aligned}$$

$$A\mathbf{x} \leq \mathbf{c}^{\max}$$

$$P_j \mathbf{x} \geq \mathbf{u}_j, P_j \mathbf{q}_j + P_j^{\text{disc}} (\mathbf{x}_j - \mathbf{q}_j) \geq \mathbf{u}_j, j=1, 2, \dots, n$$

که متغیرها \mathbf{u} هستند. حال برای اینکه نشان دهیم این LP معادله مسئله اصلی است، \mathbf{x} یک ثابت قرار می‌دهیم. آخرین set از constraint ها تعیین می‌کند که $\mathbf{u}_i \leq r_i(\mathbf{x})$ بنابراین نتیجه بگیریم که برای هر مقدار feasible \mathbf{x} و \mathbf{u} ، تابع هدف LP کمتر از مساله مجموع درآمد است. عبارت دیگر همیشه می‌توان $\mathbf{u}_i = r_i(\mathbf{x})$ را انتخاب کنیم که در این حالت دو تابع هدف برابرند.

سؤال 6: (a) برای ساده سازی عبارت، می‌توانیم $\mathbf{a}_i^T \mathbf{p} = 1$ فرض کنیم (اگر این نباشد،

$\mathbf{a}_i^T \mathbf{p}$ را به شکل $\mathbf{a}_i^T \mathbf{p} / \mathbf{a}_i^T \mathbf{p}$ تعریف می‌کنیم که باز همان مقدار است)

$$f(\mathbf{p}) = \max_i |\log \mathbf{a}_i^T \mathbf{p}|$$

و دامنه f نیز برابر است با: $\{\mathbf{p} | \mathbf{a}_i^T \mathbf{p} > 0, i=1, 2, \dots, n\}$

$$|\log(\mathbf{a}_i^T \mathbf{p})| = \max \{ \log(\mathbf{a}_i^T \mathbf{p}), 1/\log(\mathbf{a}_i^T \mathbf{p}) \} = \log \max \{ \mathbf{a}_i^T \mathbf{p}, 1/\mathbf{a}_i^T \mathbf{p} \}$$

$$\Rightarrow f(\mathbf{p}) = \log \max_i \max \{ \mathbf{a}_i^T \mathbf{p}, 1/\mathbf{a}_i^T \mathbf{p} \}$$

$\max_i \max \{ \mathbf{a}_i^T \mathbf{p}, 1/\mathbf{a}_i^T \mathbf{p} \}$ convex است، dom f هم $\mathbf{a}_i^T \mathbf{p}$ و $1/\mathbf{a}_i^T \mathbf{p}$

تابع convex است $\Rightarrow \exp f$ تابع convex است

(b) constraint / - شکل زیر می‌توان نشان داد :

$$\sum_{i=1}^L P[i] - 0.5 \sum_{i=1}^m P_i \leq 0$$

که $L=10$ است و $P[i]$ ، نامین بزرگترین مؤلفه P است . term اول ، مجموع power ، L لایه با بیشترین power است . term دوم نصف مجموع power است . term اول چون مجموع چندین $P[i]$ است ، convex است و تابع linear نیز هست .



(c) از مثال نقض استفاده می‌کنیم : P^1 و P^2 دو جواب - هستند که constraint برای

آن دو صحت می‌کند (satisfy می‌شود) . در جواب اولی m_2 تا لایه اول روشن است

و بقیه لایه ها خاموش است . ، واقع m_2 تا مؤلفه اول P^1 مثبت و بقیه صفر است .

در جواب دوم m_2 تا لایه اول خاموش و بقیه لایه ها روشن است . این هم یعنی m_2 تا

مؤلفه اول P^2 صفر و بقیه مؤلفه ها مثبت است . تعداد مؤلفه های نا صفر convex combination

P^1 و P^2 برابر m است در نتیجه constraint برای convex combination صحت نمی‌کند

⇐ این constraint ، convex نیست .

(a) است چپ equality درستی - عنوان convex مشخص شده است اما

equality constraint ها زمانی معتبر هستند که دو طرف equality ها affine باشند .
چون نرم (norm) یک برابر زمانی صفر است که خود برابر صفر باشد پس constraint را میتوان به شکل رو به رو نشان داد : $x + 2*y == 0$; $x - y == 0$;
محیط آن را به شکل $norm([x + 2*y, x - y]) \leq 0$ نیز میتوان نوشت .

(b) مشکل این جا است که square() فقط آرگومان های affine می پذیرد - این دلیل که convex است اما increasing نیست . برای رفع این اشکال باید به جای آن $square_pos()$ استفاده کنیم
 $square_pos(square(x + y)) \leq x - y$
تابع $square_pos$ به شکل رو به رو است : $square_pos(x) = square(max(x, 0))$

(c) $1/x$ convex نیست مگر اینکه دامنه آن R_{++} محدود شود اما اینجا $x \geq 0$

است . این خط را به شکل رو به رو می توانیم بنویسیم : $inv_pos(x) + inv_pos(y) \leq 1$
تابع inv_pos به شکل رو به رو است : $inv_pos(x) = 1 / max(x, 0)$

(d) مشکل این جا است که norm() فقط آرگومان های affine می پذیرد - این دلیل که convex است اما increasing نیست . یک روش برای تصحیح این خطا معرفی تغییرهای

جدید مانند u و v است .
 $norm([u, v]) \leq 3*x + y$

$$max(x, 1) \leq u$$

$$max(y, 2) \leq v$$

تجربه تابع هدف با معرفی تغییرهای جدید به این دلیل این جا به درستی کار میکند که تابع norm بر روی R^2_+ convex و monotonic است و به خصوص در این جا که $max(x, 1)$ و $max(y, 2)$

داریم بر روی $(2, \infty) \times (1, \infty)$ ، convex و monotonic است

(e) xy concave نیست پس به شکل بیان شده است، درست عمل نمی‌کند. باید شکل constraint را تغییر دهیم (به عنوان یکی از راه حل‌ها) و به شکل زیر بنویسیم.

$$x \geq \text{inv_pos}(y)$$

در اینجا جای α و β هیز می‌توان جایجا کرد.

یکی از راه حل دیگر تعریف constraint به شکل $\text{geomean}([x, y]) \geq 1$ است

که geomean میان میانگین هندسی است

$$\text{geomean}([x, y]) = \sqrt{xy}$$

(f) به این دلیل اشکال دارد که یک تابع convex را تقسیم بر یک تابع concave می‌کنیم

می‌توان عبارت را به شکل $\text{quad_over_lin}(x+y, \sqrt{y}) \leq x-y+5$ نوشت

به این دلیل که quad_over_lin در آرگومان دوم $\text{monotone decreasing}$ است، می‌تواند

تابع concave (در آن آرگومان) بپذیرد (sqrt همان تابع concave است)

(g) $x^3 + y^3$ برای $x \geq 0, y \geq 0$ convex است اما نکته اینجا است که

خبر x^3 برای $x < 0$ convex نیست پس cvx این عبارت را رد می‌کند.

یک راه برای تصحیح، نوشتن constraint به شکل زیر است:

$$\text{quad_pos_over_lin}(\text{square}(x), x) + \text{quad_pos_over_lin}(\text{square}(y), y) \leq 1$$

به این دلیل این عبارت درست است که تابع quad_pos_over_lin convex است و در

آرگومان اول increasing است، بنابراین یک تابع convex را در آرگومان اول می‌پذیرد.

سوال 5 قسمت (h) : اینجا اشکال concave نبودن xy است که باعث می شود cvx عبارت را رد کند. برای حل به نکتی بر می رویم و می بینیم که $\sqrt{xy} - z^2 = \sqrt{y(x - \frac{z^2}{y})}$ و constraint را به شکل زیر بازنویس می کنیم :

$$x + z \leq 1 + \text{geo_mean}([x - \text{quad_over_lin}(z, y)], y)$$

این عبارت درست عمل می کند چون geo_mean concave است و برای هر x و y non-decreasing است. بنابراین یک تابع concave را برای اگر توان اولش می پذیرد.

مسئله 7: (a) با استفاده از تئوری Schur complement می توان مسئله را به شکل SDP نوشت.

$$\begin{aligned} & \text{minimize } t \\ & \text{subject to } \begin{bmatrix} F(x) & c \\ c^T & t \end{bmatrix} \succeq 0 \end{aligned}$$

این را با استفاده از Schur complement می توان نوشت:

$$t - c^T F(x)^+ c \geq 0$$

$$\rightarrow t \geq c^T F(x)^+ c$$

که با توجه به minimize کردن t ، معادله مسئله اصلی است (الگوریتم)

$$F(x) = F(x)^+ \text{ برقرار باشد}$$

دقت شود که دامنه دو مسئله معادل (equivalent) نیستند. یعنی برای برخی x ها،

$F(x)$ نیمه معین مثبت (positive semidefinite) است اما معین مثبت (positive definite) نیست.

linear matrix inequality گفته در مسئله SDP بالا معادل زیر است:

$$F(x) \succeq 0, \quad c \in R(F(x)), \quad c^T F(x)^+ c \leq t$$

پس در واقع SDP نوشته شده در بالا معادل مسئله زیر است:

$$\text{minimize } c^T F(x)^+ c$$

$$\text{subject to } F(x) \succeq 0$$

$$c \in R(F(x))$$

آنگاه $F(x)$ نیمه معین مثبت و singular باشد و $c \in R(F(x))$ ، هنگام objective تابع $c^T F(x)^+ c$ محدود است در حالی که با معین شرایط objective در مسئله اصلی $+$ است. اما این مسئله optimal value مسئله را تغییر نمی دهد (بجز در حالتی که $\{x | F(x) \succ 0\}$ خالی باشد)

(b) این مسئله تقریباً مسئله فیزی است. به شکل زیر آن را بصورت SDP می نویسیم :

minimize t

subject to $\begin{bmatrix} F(x) & c_i \\ c_i^T & t \end{bmatrix} \succeq 0, i = 1, 2, \dots, k$

(c) تابع هزینه صورت سوال را بصورت $\lambda_{\max}(F(x))$ می نویسیم

$$f(x) = \lambda_{\max}(F(x)) \quad f(x) \leq t \iff F(x) \preceq tI$$

$$\Rightarrow tI - F(x) \succeq 0 \Rightarrow tI - I^T F(x) I \succeq 0$$

$$\begin{bmatrix} F(x) & I \\ I & tI \end{bmatrix} \succeq 0 \quad \begin{matrix} \overleftarrow{I^T = I} \\ \text{Schur complement} \end{matrix}$$

حال مسئله را بصورت زیر می نویسیم :

minimize t

subject to $\begin{bmatrix} F(x) & I \\ I & tI \end{bmatrix} \succeq 0$

(d) تابع هزینه را بصورت زیر می نویسیم :

$$f(x) = \bar{c}^T F(x)^{-1} \bar{c} + \text{tr}(F(x) S)$$

قرار می دهیم $S = \sum_{k=1}^m c_k c_k^T$ مسئله را می نویسیم :

$$\text{minimize } \bar{c}^T F(x)^{-1} \bar{c} + \sum_{k=1}^m c_k^T F(x)^{-1} c_k$$

حال چون مشابه حرکت از دو term تابع هزینه مسئله نوشته شده، در بخش بعدی طبق مورد میدان این مسئله را حل می‌کنیم. SDP نوشت :

$$\text{minimize } t_0 + \sum_k t_k$$

$$\text{subject to } \begin{bmatrix} F_{\infty} & \bar{c} \\ \bar{c}^T & t_0 \end{bmatrix} \succeq 0$$

$$\begin{bmatrix} F_{\infty} & c_k \\ c_k^T & t_k \end{bmatrix} \succeq 0 \quad k = 1, 2, \dots, m$$

سوال 8: مسئله در سوال معادل (equivalent) LP مسئله است:

$$\text{minimize } 1^T t$$

$$\text{subject to } Hu = x_{des}$$

$$-t \leq u \leq t$$

$$2u - 1 \leq t \quad u, t \in \mathbb{R}^n$$

$$-2u - 1 \leq t$$

$$H = [A^{N-1}b \quad A^{N-2}b \quad \dots \quad Ab \quad b]$$

سوال 9 : (a)

- (1) اگر LP relaxation، infeasible باشد آنرا
Boolean LP نیز infeasible است
- (2) مقدار optimal مربوط به LP relaxation
کمتر یا مساوی مقدار optimal مربوط به
Boolean LP است پس مقدار optimal
مربوط به LP relaxation، lower bound
مقدار optimal مربوط به Boolean LP است

feasible set مربوط به LP relaxation شامل
feasible set مربوط به Boolean LP است

(b) در این حالت می توان گفت راه حل
optimal مربوط به LP relaxation، راه حل optimal
برای Boolean LP نیز است.

(c) آید این بخش و البته سوال 10 مکرر داده شده است